

第9講 — 集中不等式

← 前の講 | README | 次の講 →

この講の目標

1. Cramér–Chernoff 法を定式化し、劣ガウス性 → Hoeffding の不等式を自力で導出できるようにする。
2. KL 型(Chernoff–Hoeffding)の境界が Hoeffding より真に鋭いことを、Pinsker の不等式と数値の両方で確認する。
3. Bernstein / 経験 Bernstein の分散項がどこから出るかを理解する。
4. サンプル数がランダムなときに何が壊れるかを明確にし、union bound / 自己正規化 / 時間一様性の 3 つの対処を整理する。
5. L&S Lemma 33.8(Track-and-Stop の正当性で使う集中不等式)を証明する。

9.1 出発点:Markov と Chebyshev

命題 9.1 【厳密】

$X \geq 0$ 、 $\varepsilon > 0$ なら $\mathbb{P}(X \geq \varepsilon) \leq \mathbb{E}[X]/\varepsilon$ 。

証明. $\varepsilon \mathbf{1}\{X \geq \varepsilon\} \leq X$ の両辺の期待値。□

$X \mapsto (X - \mathbb{E}X)^2$ に適用すれば Chebyshev の不等式 $\mathbb{P}(|X - \mathbb{E}X| \geq \varepsilon) \leq \text{Var}(X)/\varepsilon^2$ 。

集中不等式はすべて命題 9.1 の系です。違いは「どんな非負関数に適用するか」だけ。Chebyshev は x^2 、Chernoff は $e^{\lambda x}$ 、Ville は $e^{\lambda x}$ をマルチンゲール化したもの。

9.2 Cramér–Chernoff 法

定義 9.2 【厳密】

確率変数 X のキュムラント母関数を $\psi_X(\lambda) := \log \mathbb{E}[e^{\lambda X}] \in (-\infty, \infty]$ 、その Legendre 変換(Cramér 変換)を

$$\psi_X^*(\varepsilon) := \sup_{\lambda \geq 0} (\lambda \varepsilon - \psi_X(\lambda))$$

と定める。

定理 9.3(Chernoff 境界) 【厳密】

$\varepsilon > \mathbb{E}[X]$ なら $\mathbb{P}(X \geq \varepsilon) \leq \exp(-\psi_X^*(\varepsilon))$ 。

証明. $\lambda \geq 0$ に対し $x \mapsto e^{\lambda x}$ は非減少なので $\{X \geq \varepsilon\} \subset \{e^{\lambda X} \geq e^{\lambda \varepsilon}\}$ 。命題 9.1 より

$$\mathbb{P}(X \geq \varepsilon) \leq e^{-\lambda \varepsilon} \mathbb{E}[e^{\lambda X}] = \exp(-(\lambda \varepsilon - \psi_X(\lambda))).$$

$\lambda \geq 0$ について下限を取る。□

9.3 劣ガウス性**定義 9.4** 【厳密】

確率変数 X が σ -劣ガウス : $\Leftrightarrow \mathbb{E}[X] = 0$ かつ

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2 \sigma^2}{2}\right) \quad (\forall \lambda \in \mathbb{R}).$$

命題 9.5(劣ガウスの基本性質) 【厳密】

X が σ -劣ガウスなら:

1. $\mathbb{P}(X \geq \varepsilon) \leq \exp\left(-\frac{\varepsilon^2}{2\sigma^2}\right)$ 、両側で $\mathbb{P}(|X| \geq \varepsilon) \leq 2 \exp\left(-\frac{\varepsilon^2}{2\sigma^2}\right)$ 。
2. $\text{Var}(X) \leq \sigma^2$ 。
3. $X_1, \dots, X_n$ が独立でそれぞれ σ_i -劣ガウスなら、 $\sum_i X_i$ は $\sqrt{\sum_i \sigma_i^2}$ -劣ガウス。

証明. 1: 定理 9.3 で $\psi_X(\lambda) \leq \lambda^2 \sigma^2 / 2$ より $\psi_X^*(\varepsilon) \geq \sup_{\lambda \geq 0} (\lambda \varepsilon - \lambda^2 \sigma^2 / 2) = \varepsilon^2 / (2\sigma^2)$ ($\lambda = \varepsilon / \sigma^2$)。 2:

$\mathbb{E}[e^{\lambda X}] = 1 + \frac{\lambda^2}{2} \mathbb{E}[X^2] + o(\lambda^2)$ と $e^{\lambda^2 \sigma^2 / 2} = 1 + \frac{\lambda^2 \sigma^2}{2} + o(\lambda^2)$ を比較。 3: 独立性より

$\mathbb{E}[e^{\lambda \sum_i X_i}] = \prod_i \mathbb{E}[e^{\lambda X_i}] \leq \exp(\lambda^2 \sum_i \sigma_i^2 / 2)$ 。 □

補題 9.6(Hoeffding の補題) 【厳密】

$X \in [a, b]$ a.s.、 $\mathbb{E}[X] = 0$ なら X は $\frac{b-a}{2}$ -劣ガウス、すなわち

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2 (b-a)^2}{8}\right).$$

証明. $\psi(\lambda) := \log \mathbb{E}[e^{\lambda X}]$ とおく。 $\psi(0) = 0$ 、 $\psi'(0) = \mathbb{E}[X] = 0$ 。

λ を固定し、指数傾斜測度 $d\mathbb{P}_\lambda := \frac{e^{\lambda X}}{\mathbb{E}[e^{\lambda X}]} d\mathbb{P}$ を導入すると、直接計算で

$$\psi'(\lambda) = \mathbb{E}_\lambda[X], \quad \psi''(\lambda) = \text{Var}_\lambda(X).$$

$\mathbb{P}_\lambda$ の下でも $X \in [a, b]$ なので、区間に値を取る確率変数の分散の評価

$$\text{Var}_\lambda(X) \leq \mathbb{E}_\lambda \left[\left(X - \frac{a+b}{2} \right)^2 \right] \leq \frac{(b-a)^2}{4}$$

が成り立つ(1つ目は分散が「平均からの二乗距離の最小値」であること、2つ目は $|X - \frac{a+b}{2}| \leq \frac{b-a}{2}$)。よって $\psi'' \leq (b-a)^2/4$ で、Taylor の定理より

$$\psi(\lambda) = \psi(0) + \lambda\psi'(0) + \frac{\lambda^2}{2}\psi''(\theta) \leq \frac{\lambda^2(b-a)^2}{8} \quad (\exists \theta \in (0, \lambda)). \quad \square$$

定理 9.7(Hoeffding の不等式) 【厳密】

$X_1, \dots, X_n$ を独立、 $X_i \in [a_i, b_i]$ a.s. とし、 $S_n = \sum_i (X_i - \mathbb{E}[X_i])$ とすると

$$\mathbb{P}(S_n \geq \varepsilon) \leq \exp\left(-\frac{2\varepsilon^2}{\sum_i (b_i - a_i)^2}\right).$$

特に $X_i \in [0, 1]$ 、 $\hat{\mu}_n = \frac{1}{n} \sum X_i$ 、 $\mu = \mathbb{E}[X_1]$ なら

$$\mathbb{P}(\hat{\mu}_n - \mu \geq \varepsilon) \leq e^{-2n\varepsilon^2}, \quad \mathbb{P}(|\hat{\mu}_n - \mu| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

証明. 補題 9.6 と命題 9.5.3 より S_n は $\frac{1}{2}\sqrt{\sum_i (b_i - a_i)^2}$ -劣ガウス。命題 9.5.1。□

導出の3ステップ:(1) 劣ガウスの定義、(2) Chernoff 法、(3) 最適な $\lambda = \varepsilon/\sigma^2$ を代入。これを何も見ずに再現できることが第9講の合格ライン。

9.4 KL 型の境界 — Hoeffding より鋭い

定理 9.8(Chernoff–Hoeffding) 【厳密】

$X_1, \dots, X_n$ を i.i.d.、 $X_i \in [0, 1]$ 、 $\mu = \mathbb{E}[X_1]$ とする。 $q > \mu$ に対し

$$\mathbb{P}(\hat{\mu}_n \geq q) \leq \exp(-n \text{kl}(q, \mu)),$$

$q < \mu$ に対し $\mathbb{P}(\hat{\mu}_n \leq q) \leq \exp(-n \text{kl}(q, \mu))$ 。ここで $\text{kl}(q, p) = q \log \frac{q}{p} + (1-q) \log \frac{1-q}{1-p}$ 。

証明の骨格. 定理 9.3 を使う。 $[0, 1]$ 値確率変数のキュムラント母関数はベルヌーイのそれで上から抑えられる:

$$\mathbb{E}[e^{\lambda X}] \leq 1 - \mu + \mu e^\lambda \quad (\lambda > 0)$$

(理由: $x \mapsto e^{\lambda x}$ は凸なので $[0, 1]$ 上で $e^{\lambda x} \leq 1 - x + x e^\lambda$ 、期待値を取る)。したがって

$\psi_X(\lambda) \leq \log(1 - \mu + \mu e^\lambda) = \psi_{\text{Ber}(\mu)}(\lambda)$ で、Legendre 変換を計算すると

$$\sup_{\lambda \geq 0} (\lambda q - \log(1 - \mu + \mu e^\lambda)) = \text{kl}(q, \mu) \quad (q > \mu)$$

($\lambda^* = \log \frac{q(1-\mu)}{\mu(1-q)}$ で達成)。あとは定理 9.3。□

命題 9.9(Pinsker、ベルヌーイ版) 【厳密, 検証:数値】

$$\text{kl}(q, p) \geq 2(q-p)^2.$$

証明. $g(q) := \text{kl}(q, p) - 2(q-p)^2$ とおくと $g(p) = 0$ 、 $g'(q) = \log \frac{q(1-p)}{p(1-q)} - 4(q-p)$ 、 $g'(p) = 0$ 、

$$g''(q) = \frac{1}{q(1-q)} - 4 \geq 0 \quad (\because q(1-q) \leq 1/4).$$

よって g' は $(0, 1)$ 上で非減少。 $g'(p) = 0$ と合わせると、 $q \in [0, 1]$ で $g'(q) \geq 0$ 。したがって g は $q=p$ で最小値 $g(p)=0$ を取る。 $\square$

帰結: $\exp(-n \text{kl}(q, \mu)) \leq \exp(-2n(q - \mu)^2)$ 、すなわち KL 型は Hoeffding より必ず鋭い。

数値比較 【検証:数値】

`code/verify_claims.py` の `check_hoeffding_vs_kl_vs_exact`。 $X_i \sim \text{Ber}(p)$ 、 $\varepsilon = q - p$ 。

厳密値は $\mathbb{P}(\hat{\mu}_n \geq q) = \mathbb{P}(\text{Bin}(n, p) \geq \lceil nq \rceil) (q = p + \varepsilon)$ 。

p	n	ε	厳密(Bin)	KL 型	Hoeffding
0.5	200	0.1	2.84×10^{-3}	1.78×10^{-2}	1.83×10^{-2}
0.1	200	0.05	1.63×10^{-2}	8.66×10^{-2}	3.68×10^{-1}
0.1	200	0.1	1.70×10^{-5}	1.39×10^{-4}	1.83×10^{-2}

読み取り: - $p = 1/2$ では KL 型と Hoeffding はほぼ同じ(分散が最大なので Hoeffding が緩くない)。 - p が 0 や 1 に近いと KL 型が圧倒的に良い(最後の行で 130 倍)。Hoeffding は分散を $1/4$ と見なすので、実際の分散 $p(1-p) = 0.09$ を活かさない。 - どちらも厳密値より緩い(Chernoff 境界の宿命)。

BAI での意味: ベルヌーイ腕で μ が 0 や 1 に近い設定(創薬スクリーニングでの「当たり率 1%」など)では、KL 型を使うかどうかで必要サンプル数が桁で変わります。これが KL-LUCB(第16講)が KL 型を使う理由です。

9.5 Bernstein 型 — 分散を使う

定理 9.10(Bernstein の不等式) 【証明省略】

$X_1, \dots, X_n$ を独立、 $\mathbb{E}[X_i] = 0$ 、 $|X_i| \leq b$ a.s.、 $v := \sum_i \mathbb{E}[X_i^2]$ とすると

$$\mathbb{P}\left(\sum_i X_i \geq \varepsilon\right) \leq \exp\left(-\frac{\varepsilon^2}{2\left(v + \frac{b\varepsilon}{3}\right)}\right).$$

出典: Boucheron–Lugosi–Massart, *Concentration Inequalities*, Theorem 2.10。 【要出典確認】 (定理番号は未照合。BLM では Bennett の不等式と Bernstein の不等式が連番で並んでおり、どちらが 2.10 かを原典で確認してください。) 分散項がどこから出るか: 証明の核は Bernstein 条件 $\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2 \mathbb{E}[X^2]/2}{1 - b\lambda/3}\right)$ で、これは $e^x \leq 1 + x + \frac{x^2/2}{1-x/3}$ ($x < 3$) という初等不等式から出ます。 $\mathbb{E}[X^2]$ が Taylor 展開の 2 次の係数として現れるのが本質。Hoeffding は $\mathbb{E}[X^2]$ を最悪値 b^2 で置き換えているので、分散が小さいときに損をします。

定理 9.11(経験 Bernstein) 【要出典確認】

$X_1, \dots, X_n$ i.i.d.、 $X_i \in [0, 1]$ 、経験分散 $\hat{V}_n = \frac{1}{n(n-1)} \sum_{i \neq j} (X_i - X_j)^2$

Maurer & Pontil (COLT 2009) / Audibert, Munos, Szepesvári (TCS 2009) の形。定数($3/\delta$ か $2/\delta$ か、 $3 \log / n$ か $7 \log / (3(n-1))$ か)は文献によって異なります。使う前に原論文で確認してください。

なぜ BAI で要るか: 真の分散 $\text{Var}(X)$ は未知なので、Bernstein をそのまま使えない。経験分散で置き換えたのが経験 Bernstein で、リスク考慮型 BAI(平均分散基準、第18講)では分散そのものが推定対象になるため必須の道具になります。

9.6 サンプル数がランダムなとき

ここが BAI 固有の難所です。

9.6.1 何が壊れるか 【厳密】

定理 9.7 は「 n を固定して」成り立ちます。バンディットでは腕 a のサンプル数 $N_a(t)$ がデータに依存する確率変数なので、 $\hat{\mu}_a(t) = \frac{1}{N_a(t)} S_a(t)$ に定理 9.7 を $n = N_a(t)$ として適用することはできません。

具体的には、reward stack model(第3講 §3.3.3)で $\hat{\mu}_{a,s} := \frac{1}{s} \sum_{r \leq s} X_{r,a}$ と書くと、 $\hat{\mu}_a(t) = \hat{\mu}_{a,N_a(t)}$ であり、 $N_a(t)$ は $(X_{r,a})_r$ に依存します。「最も都合のよい s を選ぶ」ことが可能になっている。

第7講 §7.5 の数値実験(固定時刻 CI が δ の 2.6 倍破れる)がこの現象です。

9.6.2 3つの対処 【厳密】

対処	方法	代償	どこで使うか
(i) union bound	全ての $s \in \mathbb{N}$ について δ_s を配分し、 $\sum_s \delta_s = \delta$	$\log s$ または $\log \log s$ の項	L&S Lemma 33.8、逐次棄却
(ii) 時間一様 (Ville)	混合マルチンゲール + Ville	$\frac{1}{2} \log \frac{t+\rho}{\rho}$ 等	第8講、Track-and-Stop
(iii) 自己正規化	S_t を $\sqrt{V_t}$ で正規化した量に対する境界	$\log \det$ 型の項	線形バンディット

(i) と (ii) は実は同じものです。(i) の union bound は「stitching の粗い版」であり、(ii) の混合は「連続的な union bound」と読めます。

補題 9.12(L&S Lemma 33.8:ガウスの時間一様境界) 【厳密】

$X_1, X_2, \dots$ を独立な $\mathcal{N}(\mu, 1)$ 、 $\hat{\mu}_n = \frac{1}{n} \sum_{t \leq n} X_t$ とする。任意の $\delta \in (0, 1)$ について

$$\mathbb{P} \left(\exists n \in \mathbb{N}_+ : \frac{n}{2} (\hat{\mu}_n - \mu)^2 \geq \log \frac{1}{\delta} + \log (n(n+1)) \right) \leq \delta.$$

証明. 各 n を固定すると $Z_n := \sqrt{n}(\hat{\mu}_n - \mu) \sim \mathcal{N}(0, 1)$ 。標準正規の両側裾に対する評価

$$\mathbb{P}(|Z| \geq z) \leq e^{-z^2/2} \quad (z \geq 0) \quad (9.1)$$

【検証:数値】(`check_normal_two_sided_tail`、 $z = 0$ で等号、以降は真に成立)を $z = \sqrt{2u}$ で使うと、 $u > 0$ に対し

$$\mathbb{P}\left(\frac{n}{2}(\hat{\mu}_n - \mu)^2 \geq u\right) = \mathbb{P}(|Z_n| \geq \sqrt{2u}) \leq e^{-u}.$$

$u = u_n := \log(1/\delta) + \log(n(n+1))$ と取ると右辺は $\frac{\delta}{n(n+1)}$ 。union bound と $\sum_{n \geq 1} \frac{1}{n(n+1)} = 1$ より、全体の確率は δ 以下。□

(9.1) について: 素朴に命題 9.5.1(両側)を使うと $2e^{-z^2/2}$ になり、係数 2 が付きます。(9.1) はそれより 2 倍鋭い評価で、 $z = 0$ で等号($1 \leq 1$)、 $z > 0$ で真に成立します。ただし (9.1) は標準正規に固有の評価であり、劣ガウスでは成り立ちません(σ -劣ガウスから言えるのは両側 $2e^{-z^2/2}$ まで)。証明は初等的です:

$h(z) := e^{-z^2/2} - \mathbb{P}(|Z| \geq z)$ とおくと $h(0) = 0$ 、 $h'(z) = e^{-z^2/2}(\sqrt{2/\pi} - z)$ なので h は $[0, \sqrt{2/\pi}]$ で増加、その後減少して $h(\infty) = 0$ 。よって $h \geq 0$ (演習 ★9-6)。【検証:数値】 $z \in [0, 8]$ の 80001 点で $h \geq 0$ を確認(最小値 0、 $z = 0$ でのみ等号)。

L&S の記述との照合【検証:PDF】: 補題 9.12 は L&S Lemma 33.8(印刷ページ p.411)そのものです。L&S は「これは Corollary 5.5 と union bound から従う」と書いていますが、Corollary 5.5(印刷ページ p.78)は劣ガウスの片側評価 $\mathbb{P}(\hat{\mu} \geq \mu + \varepsilon) \leq \exp(-n\varepsilon^2/(2\sigma^2))$ であり、その直前の頁で両側版は $2\exp(-\varepsilon^2/(2\sigma^2))$ と明記されています。両側版をそのまま使うと union bound の合計が 2δ になり、Lemma 33.8 の δ には届きません。 δ を出すには、上の (9.1)(ガウス固有の両側評価)が必要です。Lemma 33.8 は仮定が「独立なガウス」なので結論自体は正しく、引用されている補題だけでは 2 倍足りない、という形のギャップです。BAI の論文では、この種の定数 2 の差が頻繁に現れます。自分で追う癖をつけてください。

命題 9.13(L&S Proposition 33.9:腕を束ねる)【証明省略, 検証:PDF】

$g: \mathbb{N}_+ \rightarrow \mathbb{R}$ を増加関数とし、各 $i \in [K]$ について確率変数列 $S_{i1}, S_{i2}, \dots$ が

$$\mathbb{P}(\exists s \in \mathbb{N}_+ : S_{is} \geq g(s) + \log(1/\delta)) \leq \delta \quad (\forall \delta \in (0, 1))$$

を満たすとする。 $(S_{i\cdot})_{i=1}^K$ が独立なら、 $x \geq K$ に対し

$$\mathbb{P}\left(\exists s \in \mathbb{N}_+^K : \sum_{i=1}^K S_{is_i} \geq K g\left(\sum_{i=1}^K s_i\right) + x\right) \leq \left(\frac{x}{K}\right)^K e^{K-x} =: f(x).$$

出典: L&S Proposition 33.9 [【検証:PDF】](#) (印刷ページ p.412 = PDF 421 ページ。内側の引数は $\sum_i s_i$ 、右辺は $(x/k)^k \exp(k-x)$ で、上の記述と一致することを原文で確認済み)。

証明の骨格: $W_i = \max_{w \in [0,1]} S_{\{i\}}$ ここで使うのは g の単調増加性だけで、 $g > 0$ は不要です ($\sum_i g(s_i) \leq K \max_i g(s_i) = Kg(\max_i s_i)$ は単調性から従う)。

注($x \geq K$ の条件): L&S の原文は「 $x \geq 0$ 」と書かれていますが、これは誤りです。Gamma($K, 1$) の Chernoff 境界 $\mathbb{P}(\geq x) \leq (x/K)^K e^{K-x}$ は最適な指数パラメータが $\lambda = 1 - K/x \geq 0$ であることを要求するので $x \geq K$ が必要で、実際 \$x\$ 本講義資料では $x \geq K$ を採用します。第15講で使うのは $x = f^{-1}(\delta) \geq K$ なので、この修正は下流に影響しません。

右辺が $f(x) = e^{K-x}(x/K)^K$ です。第8講 §8.4 で見た L&S の閾値 $\beta_t(\delta) = K \log(t^2 + t) + f^{-1}(\delta)$ の f はここから来ています。 $g(s) = \log(s(s+1))$ 、 $\sum_i s_i = t$ とすれば $Kg(t) = K \log(t^2 + t)$ 。第15講でこの組み立てを使います。

9.7 まとめ

- 集中不等式はすべて Markov の不等式 + 適当な非負関数。
- 劣ガウス → Chernoff → 最適な λ の 3 ステップで Hoeffding が出る。
- KL 型(Chernoff-Hoeffding)は Hoeffding より必ず鋭い(Pinsker)。 p が端に近いと差は桁で効く。
- Bernstein の分散項は e^x の Taylor 展開の 2 次係数。経験 Bernstein は分散も推定する。
- サンプル数がランダムなら固定 n の不等式は使えない。対処は union bound / 時間一様 / 自己正規化。
- L&S Lemma 33.8 + Proposition 33.9 が Track-and-Stop の閾値の出どころ。

演習(詳細は B-exercises.md §9)

- ★9-1 Hoeffding の不等式を、劣ガウスの定義から何も見ずに導出せよ。
- ★9-2 補題 9.6(Hoeffding の補題)の証明で、 $\psi''(\lambda) = \text{Var}_\lambda(X)$ を直接計算で確かめよ。
- ★9-3 定理 9.8 の Legendre 変換 $\sup_\lambda (\lambda q - \log(1 - \mu + \mu e^\lambda)) = \text{kl}(q, \mu)$ を計算せよ。
- ★9-4 $n = 100, 1000, 10000$ について、Hoeffding 境界・KL 型境界・厳密な二項裾を $p = 0.5$ と $p = 0.05$ で数値比較せよ。
- ★9-5 補題 9.12 を自分で導出し、 $\sum_{n \geq 1} \frac{1}{n(n+1)} = 1$ を確認せよ。 $\log(n(n+1))$ を $2 \log \log n$ 型に改良できるか考えよ(ヒント:第8講 定理 8.4)。
- ★9-6 式 (9.1) $\mathbb{P}(|Z| \geq z) \leq e^{-z^2/2}$ ($Z \sim \mathcal{N}(0, 1)$ 、 $z \geq 0$)を証明せよ。 $z = 0$ で等号になることを確認し、素朴な $2e^{-z^2/2}$ との差を数値で見よ。
- ☆9-7 命題 9.13 を証明せよ($-\log W_i$ が $\text{Exp}(1)$ で抑えられること、Gamma($K, 1$) の裾評価 $\mathbb{P}(\geq x) \leq (x/K)^K e^{K-x}$ が必要。L&S Exercise 5.16)。
- ☆9-8 経験 Bernstein の定数を、Maurer-Pontil の原論文で確認し、定理 9.11 の記述を訂正せよ。

[← 前の講](#) | [次の講: 情報理論](#) →