

第10講 — KL ダイバージェンスとデータ処理不等式

← 前の講 | README | 次の講 →

この講の目標

1. 一般の可測空間上で KL ダイバージェンスを定義し、Radon–Nikodým 微分による表現を得る。
2. データ処理不等式を証明する。BAI の下界の Step 2 はこれそのもの。
3. Bretagnolle–Huber の不等式を完全に証明する (L&S 版の下界で使う)。
4. Pinsker の不等式、Donsker–Varadhan の変分表現を押さえる。
5. $\text{kl}(\delta, 1 - \delta)$ と $\log \frac{1}{2.4\delta}$ 、 $\log \frac{1}{4\delta}$ の関係を数値で確定させる。

10.1 定義

定義 10.1(離散化による定義) 【厳密】

$(\Omega, \mathcal{F})$ 上の確率測度 P, Q に対し

$$\text{KL}(P, Q) := \sup \left\{ \sum_{i=1}^N P(A_i) \log \frac{P(A_i)}{Q(A_i)} : N \in \mathbb{N}, \{A_i\}_{i=1}^N \text{ は } \mathcal{F} \text{ の有限可測分割} \right\}$$

と定める。規約: $0 \log \frac{0}{0} = 0$ 、 $0 \log \frac{0}{q} = 0$ 、 $p \log \frac{p}{0} = +\infty (p > 0)$ 。

なぜこの定義か: 「有限個の記号に離散化して符号化したときの、余分に必要なビット数の上限」。Ω が非可算でもエントロピーが定義できないのに相対エントロピーは定義できる、という状況をきれいに扱えます。L&S § 14.2 の説明がこの立場です。 【検証:PDF】 (L&S 第14章は印刷ページ p.186 から、§ 14.2 Relative Entropy は p.188–190)

定理 10.2(Radon–Nikodým 表現) 【証明省略】

$$\text{KL}(P, Q) = \begin{cases} \int_{\Omega} \log \frac{dP}{dQ} dP & (P \ll Q) \\ +\infty & (\text{それ以外}) \end{cases}$$

共通の σ -有限支配測度 λ と密度 $p = dP/d\lambda$ 、 $q = dQ/d\lambda$ があれば

$$\text{KL}(P, Q) = \int_{\{p>0\}} p \log \frac{p}{q} d\lambda.$$

出典: L&S Theorem 14.1 【検証:PDF】 (印刷ページ p.189 = PDF 198 ページ)。密度による表現は同ページの式 (14.6)。 $\lambda = P + Q$ は常に取れます (L&S も同じ注意を書いています)。

命題 10.3(非負性) 【厳密】

$KL(P, Q) \geq 0$ 、等号 $\iff P = Q$ 。

証明. $P \not\ll Q$ なら $KL = +\infty > 0$ で自明。以下 $P \ll Q$ とし $Z := dP/dQ$ とおくと $\mathbb{E}_Q[Z] = 1$ で

$$KL(P, Q) = \mathbb{E}_P[\log Z] = \mathbb{E}_Q[Z \log Z] = \mathbb{E}_Q[\varphi(Z)], \quad \varphi(x) := x \log x.$$

φ は $(0, \infty)$ 上で狭義凸($\varphi''(x) = 1/x > 0$)なので、Jensen の不等式より

$$\mathbb{E}_Q[\varphi(Z)] \geq \varphi(\mathbb{E}_Q[Z]) = \varphi(1) = 0.$$

狭義凸性より等号は Z が Q -a.s. 定数のとき、すなわち $Z = 1$ Q -a.s.、すなわち $P = Q$ のときに限る。□

例 10.4(基本的な KL) 【厳密, 検証:PDF】

分布の組	KL
$\mathcal{N}(\mu_1, \sigma^2), \mathcal{N}(\mu_2, \sigma^2)$	$\frac{(\mu_1 - \mu_2)^2}{2\sigma^2}$
$\mathcal{N}(\mu_1, \sigma_1^2), \mathcal{N}(\mu_2, \sigma_2^2)$	$\frac{(\mu_1 - \mu_2)^2}{2\sigma_2^2} + \frac{1}{2} \left(\frac{\sigma_1^2}{\sigma_2^2} - 1 - \log \frac{\sigma_1^2}{\sigma_2^2} \right)$
$\text{Ber}(p), \text{Ber}(q)$	$\text{kl}(p, q) = p \log \frac{p}{q} + (1-p) \log \frac{1-p}{1-q}$
$\text{Exp}(\lambda_1), \text{Exp}(\lambda_2)$	$\log \frac{\lambda_1}{\lambda_2} + \frac{\lambda_2}{\lambda_1} - 1$

出典の内訳 【検証:PDF】: L&S に載っているのは 1 行目(共通分散ガウス、印刷ページ p.189)と 3 行目(ベルヌーイ、p.189 末~p.190、L&S はこれを $d(p, q)$ と略記)の 2 つだけです。2 行目(異分散ガウス)と 4 行目(指数分布)は L&S にはありません(★10-3 で自分で計算してください。本資料では独立に検算済み)。 $\text{kl}(p, q)$ という記法は BAI の論文で最頻出です。

10.1.1 1 パラメータ指数型分布族 【厳密】

BAI の理論は通常、次のクラスで展開されます。

$$\frac{d\nu_\theta}{d\lambda}(x) = \exp(\theta x - b(\theta)), \quad \theta \in \Theta \subset \mathbb{R}$$

(b は対数分配関数)。平均は $\mu(\theta) = b'(\theta)$ 、分散は $b''(\theta) > 0$ なので $\theta \mapsto \mu$ は狭義増加。

$$KL(\nu_\theta, \nu_{\theta'}) = (\theta - \theta')b'(\theta) - b(\theta) + b(\theta') =: d(\mu, \mu')$$

と、平均でパラメータ付けした $d(\cdot, \cdot)$ が定まる。ガウス(既知分散)・ベルヌーイ・ポアソン・指数分布はすべてこのクラス。

重要な性質 【厳密】: μ を固定すると $\mu' \mapsto d(\mu, \mu')$ は $\mu' < \mu$ で狭義減少、 $\mu' > \mu$ で狭義増加、 $d(\mu, \mu) = 0$ 。 μ' を固定すると $\mu \mapsto d(\mu, \mu')$ は凸。これらは第14講で $T^*(\nu)$ の最適化問題を解くときに使います。

10.2 chain rule とデータ処理不等式

定理 10.5(chain rule) 【証明省略】

$(\mathcal{X} \times \mathcal{Y})$ 上の確率測度 P, Q を、周辺分布 P_X, Q_X と条件付き核 $P_{Y|X}, Q_{Y|X}$ に分解すると

$$\text{KL}(P, Q) = \text{KL}(P_X, Q_X) + \int_{\mathcal{X}} \text{KL}(P_{Y|X=x}, Q_{Y|X=x}) P_X(dx).$$

出典: Kallenberg / Cover-Thomas Theorem 2.5.3(離散版)。 【要出典確認】 (定理番号は未照合) 証明は Radon-Nikodým 微分の分解 $\frac{dP}{dQ} = \frac{dP_X}{dQ_X} \cdot \frac{dP_{Y|X}}{dQ_{Y|X}}$ と Fubini。第3講の発散分解(定理 3.9)は、この chain rule を n 回繰り返したものと見ることもできます。

定理 10.6(データ処理不等式, DPI) 【厳密】

$T: (\Omega, \mathcal{F}) \rightarrow (\mathcal{E}, \mathcal{G})$ を可測写像とすると

$$\text{KL}(P \circ T^{-1}, Q \circ T^{-1}) \leq \text{KL}(P, Q).$$

証明. 定義 10.1 を使う。 $\{B_i\}_{i=1}^N$ を $\mathcal{E}$ の有限可測分割とすると、 $\{T^{-1}(B_i)\}_{i=1}^N$ は $\mathcal{F}$ の有限可測分割であり

$$\sum_i (P \circ T^{-1})(B_i) \log \frac{(P \circ T^{-1})(B_i)}{(Q \circ T^{-1})(B_i)} = \sum_i P(T^{-1}B_i) \log \frac{P(T^{-1}B_i)}{Q(T^{-1}B_i)} \leq \text{KL}(P, Q).$$

$\{B_i\}$ について上限を取ればよい。□

定義 10.1(離散化による定義)を採用したご褒美が、この 3 行の証明です。Radon-Nikodým 表現から出発すると条件付き Jensen を経由することになり、もう少し手間がかかります。

系 10.7(事象への適用 = 輸送不等式) 【厳密】

BAI の下界の Step 2 はこれです。

任意の $A \in \mathcal{F}$ について

$$\text{KL}(P, Q) \geq \text{kl}(P(A), Q(A)),$$

ここで kl はベルヌーイ KL。

証明. $T = \mathbf{1}_A: \Omega \rightarrow \{0, 1\}$ とすると $P \circ T^{-1} = \text{Ber}(P(A))$ 、 $Q \circ T^{-1} = \text{Ber}(Q(A))$ 。定理 10.6。□

読み方: 「 Ω 上の全情報を『 A が起きたか否か』の 1 ビットに潰しても、区別しやすさは増えない」。当たり前の主張ですが、これが下界の全体を支えます。

$\sup_{A \in \mathcal{F}} \text{kl}(P(A), Q(A))$ は実は $\text{KL}(P, Q)$ に等しくはありません(1 ビットへの潰しは一般に情報を失う)。しかし BAI では「誤答する事象」という特定の A について評価すれば足りるので、これで十分です。

定理 10.8(Donsker–Varadhan の変分表現) 【証明省略】

$$\text{KL}(P, Q) = \sup \{ \mathbb{E}_P[f] - \log \mathbb{E}_Q[e^f] : f : \Omega \rightarrow \mathbb{R} \text{ 可測}, \mathbb{E}_Q[e^f] < \infty \}.$$

出典: Boucheron–Lugosi–Massart, Corollary 4.15。 【要出典確認】 (定理番号は未照合) 使い道: 「KL が小さければ、任意の有界関数の期待値も近い」という形の主張(transportation inequality)を出すのに使います。第18講の非漸近解析で現れます。

10.3 Pinsker と Bretagnolle–Huber

定義 10.9(全変動距離) 【厳密】

$$\text{TV}(P, Q) := \sup_{A \in \mathcal{F}} |P(A) - Q(A)| = \frac{1}{2} \int |p - q| d\lambda = 1 - \int \min(p, q) d\lambda.$$

(最後の2つの等式は $\int (p - q)^+ d\lambda = \int (q - p)^+ d\lambda$ と $\min = \frac{p+q-|p-q|}{2}$ から。)

定理 10.10(Pinsker の不等式) 【厳密】

$$\text{KL}(P, Q) \geq 2 \text{TV}(P, Q)^2.$$

証明.(系 10.7 と 命題 9.9 を認めれば完結します。)系 10.7 で A を TV を達成する事象 $\{p > q\}$ に取ると $\text{KL}(P, Q) \geq \text{kl}(P(A), Q(A))$ 。ベルヌーイ版の Pinsker(第9講 命題 9.9) $\text{kl}(x, y) \geq 2(x - y)^2$ を適用し、 $P(A) - Q(A) = \text{TV}(P, Q)$ を使う。□

DPI + ベルヌーイ版で一般版が出るという構造に注目してください。多くの不等式がこの形(1 ビットに潰して初等的に解く)で証明できます。

定理 10.11(Bretagnolle–Huber の不等式) 【厳密】

同じ可測空間上の確率測度 P, Q と任意の $A \in \mathcal{F}$ について

$$P(A) + Q(A^c) \geq \frac{1}{2} \exp(-\text{KL}(P, Q)).$$

証明. $\text{KL}(P, Q) = \infty$ なら自明。以下 $P \ll Q$ とし、共通支配測度 λ 、密度 p, q を取る。

$$\text{Step 1. } P(A) + Q(A^c) = \int_A p d\lambda + \int_{A^c} q d\lambda \geq \int_A \min(p, q) d\lambda + \int_{A^c} \min(p, q) d\lambda = \int \min(p, q) d\lambda.$$

Step 2(Cauchy–Schwarz). $\max(p, q) \leq p + q$ より $\int \max(p, q) d\lambda \leq 2$ 。したがって

$$\left(\int \sqrt{pq} d\lambda \right)^2 = \left(\int \sqrt{\min(p, q)} \sqrt{\max(p, q)} d\lambda \right)^2 \leq \left(\int \min(p, q) d\lambda \right) \left(\int \max(p, q) d\lambda \right) \leq 2 \int \min(p, q) d\lambda.$$

Step 3(Jensen). $\int \sqrt{pq} d\lambda = \mathbb{E}_P \left[\sqrt{q/p} \right] = \mathbb{E}_P \left[\exp \left(\frac{1}{2} \log \frac{q}{p} \right) \right] \geq \exp \left(\frac{1}{2} \mathbb{E}_P \left[\log \frac{q}{p} \right] \right) = \exp \left(-\frac{1}{2} \text{KL}(P, Q) \right)$ (exp の凸性と Jensen)。

まとめ. Step 2, 3 より $\int \min(p, q) d\lambda \geq \frac{1}{2} \left(\int \sqrt{pq} d\lambda \right)^2 \geq \frac{1}{2} e^{-\text{KL}(P, Q)}$ 。Step 1 と合わせる。□

これは L&S Theorem 14.2 です。【検証:PDF】(L&S p.190)【検証:数値】(`check_bretagnolle_huber`:ベルヌーイの全組合せ 99×99 と全事象で最小スラック $1.4 \times 10^{-2} > 0$)

なぜ Pinsker でなく Bretagnolle–Huber か。下界では「KL が大きくなると $P(A) + Q(A^c)$ が小さくできない」を使いたい。Pinsker から得られる $P(A) + Q(A^c) \geq 1 - \sqrt{KL/2}$ は $KL > 2$ で自明になってしまいます。

Bretagnolle–Huber は KL が大きい領域でも意味を持つ(指数的にしか減らない)ので、 $\delta \rightarrow 0$ の漸近論に使えます。

10.4 $\text{kl}(\delta, 1 - \delta)$ の評価 — 下界の定数

BAI の下界には $\text{kl}(\delta, 1 - \delta)$ が現れます。使いやすい形に落としておきます。

命題 10.12 【厳密, 検証:数値】

$\delta \in (0, 1/2)$ について

$$\text{kl}(\delta, 1 - \delta) = (1 - 2\delta) \log \frac{1 - \delta}{\delta}.$$

さらに

$$\text{kl}(\delta, 1 - \delta) \geq \log \frac{1}{2.4\delta} \geq \log \frac{1}{4\delta} \quad \text{かつ} \quad \lim_{\delta \rightarrow 0} \frac{\text{kl}(\delta, 1 - \delta)}{\log(1/\delta)} = 1.$$

証明(等式部分).

$$\text{kl}(\delta, 1 - \delta) = \delta \log \frac{\delta}{1 - \delta} + (1 - \delta) \log \frac{1 - \delta}{\delta} = (1 - 2\delta) \log \frac{1 - \delta}{\delta}. \quad \square$$

不等式部分【検証:数値】: `code/verify_claims.py` の `check_delta_functions` で $\delta \in (0, 1/2)$ の 800 点(対数格子 + 等間隔格子)を検査。

主張	結果
$\text{kl}(\delta, 1 - \delta) \geq \log \frac{1}{2.4\delta}$	成立(最小マージン 7.3×10^{-3})
$\text{kl}(\delta, 1 - \delta) \geq \log \frac{1}{4\delta}$	成立(最小マージン 0.518。これは $\log(4/2.4) = 0.5108$ に 2.4 版の最小マージン 0.0073 を足した値)
定数を $2.4 \rightarrow 2$ にすると	$\delta \approx 0.155$ で破れる(定数 2.4 はほぼ最良)
$\text{kl}(\delta, 1 - \delta) / \log(1/\delta)$ at $\delta = 10^{-12}$	1.000001

文献との対応: - KCG2016 / GK2016 の下界は $\mathbb{E}[\tau] \geq T^*(\nu) \text{kl}(\delta, 1 - \delta)$ の形。 - L&S Theorem 33.5 は $\mathbb{E}_{\nu\pi}[\tau] \geq c^*(\nu) \log \frac{1}{4\delta}$ の形($c^*(\nu)$ が本資料の $T^*(\nu)$)。【検証:PDF】(L&S 印刷ページ p.407 = PDF 416 ページ)
 両者の差は証明で使う不等式の違いです。L&S は Bretagnolle–Huber(定理 10.11)を使うので $\log \frac{1}{4\delta}$ 、KCG は データ処理不等式(系 10.7)を使うので $\text{kl}(\delta, 1 - \delta)$ 。上の数値が示すとおり KCG 側の方が真に強い($\log \frac{1}{2.4\delta}$ まで言える)。第13講では両方の道を示します。

10.5 バンディットの発散分解(再掲と位置づけ)

第3講 定理 3.9 と 第6講 定理 6.10 を、この講の言葉で書き直しておきます。

$$\text{KL}(\mathbb{P}_{\nu\pi}^{\mathcal{F}_\tau}, \mathbb{P}_{\nu'\pi}^{\mathcal{F}_\tau}) = \sum_{a=1}^K \mathbb{E}_{\nu\pi}[N_a(\tau)] \text{KL}(\nu_a, \nu'_a).$$

これと系 10.7(A = 誤答事象)を組み合わせるだけで下界が出ます。残っているのは「どの ν' を選ぶか」という最適化問題だけで、それが第14講の $T^*(\nu)$ です。

10.6 まとめ

- KL は離散化の上限として定義するのが一般的で扱いやすい。 $P \ll Q$ なら $\mathbb{E}_P[\log \frac{dP}{dQ}]$ 。
- データ処理不等式は定義から 3 行。事象に適用した系 10.7 が下界の Step 2。
- Bretagnolle–Huber $P(A) + Q(A^c) \geq \frac{1}{2}e^{-\text{KL}}$ は Cauchy–Schwarz + Jensen の 3 ステップ。KL が大きい領域でも有効なのが利点。
- $\text{kl}(\delta, 1 - \delta) = (1 - 2\delta) \log \frac{1-\delta}{\delta} \geq \log \frac{1}{2.4\delta}$ 、 $\delta \rightarrow 0$ で $\sim \log(1/\delta)$ 。
- 指数型分布族では KL が平均のみの関数 $d(\mu, \mu')$ になり、第14講の最適化が解ける形になる。

演習(詳細は B-exercises.md § 10)

- ★10-1 定理 10.6(DPI)を、定義 10.1 から自分で証明せよ。
- ★10-2 定理 10.11(Bretagnolle–Huber)の 3 ステップを何も見ずに再現せよ。
- ★10-3 例 10.4 のガウス(異分散)の KL を直接計算せよ。 $\sigma_1 = \sigma_2$ のとき既知の式に帰着することを確認。
- ★10-4 2 腕($K = 2$)の場合に、 $\text{KL}(\mathcal{N}(\mu_1, 1), \mathcal{N}(m, 1))$ と $\text{kl}(p, q)$ を手で計算し、 $\mu = (0.6, 0.45)$ 、 $m = 0.5$ などの具体値で数値を出せ。
- ★10-5 命題 10.12 の不等式 $\text{kl}(\delta, 1 - \delta) \geq \log \frac{1}{2.4\delta}$ を解析的に証明せよ(数値検証は済んでいる。 $\delta \leq 0.15$ と $\delta > 0.15$ で場合分けするのが素直)。
- ☆10-6 Pinsker の不等式を Bretagnolle–Huber から導けるか。逆はどうか。どちらがどの領域で強いかを図示せよ。

- ☆10-7 指数型分布族で $d(\mu, \mu')$ が μ について凸であることを示せ。
-

← 前の講 | 次の講: 逐次検定と e-value →