

第11講 — 仮説検定、逐次検定、e-value

← 前の講 | README | 次の講 →

この講の目標

1. 検定の枠組み(第一種・第二種の過誤、検出力)を定義し、過誤確率と KL の関係をデータ処理不等式から導く。
2. Neyman–Pearson の補題と、逐次確率比検定(SPRT)を押さえる。
3. 一般化尤度比(GLR)統計量を定義し、指数型分布族での閉形式を導出する。これが Track-and-Stop の停止統計量そのものの。
4. e-value / e-process / test マルチンゲールを定義し、Ville の不等式との関係を整理する。
5. 「BAI は逐次多重検定である」という視点を得る。

この講は BAI の「統計」側の言葉を揃えるためのものです。数学的に新しい道具はほとんど出てきません(すべて第7・10講の系)。しかし論文の書き方は完全に検定の言葉なので、ここを通しておかないと読めません。

11.1 検定の枠組み

定義 11.1 【厳密】

観測 X の分布が P_0 (帰無仮説 H_0)か P_1 (対立仮説 H_1)かを判定する。検定とは可測関数 $\varphi: \Omega \rightarrow \{0, 1\}$ ($1 = H_0$ を棄却)。

- 第一種の過誤(type I error, 有意水準): $\alpha(\varphi) := P_0(\varphi = 1)$
- 第二種の過誤(type II error): $\beta(\varphi) := P_1(\varphi = 0)$
- 検出力(power): $1 - \beta(\varphi) = P_1(\varphi = 1)$

定理 11.2(過誤確率の情報理論的下界) 【厳密】

任意の検定 φ について

$$\text{kl}(\alpha(\varphi), 1 - \beta(\varphi)) \leq \text{KL}(P_0, P_1),$$

また

$$\alpha(\varphi) + \beta(\varphi) \geq \frac{1}{2} \exp(-\text{KL}(P_0, P_1)).$$

証明. 第1式: 系 10.7(DPI を $T = \varphi$ に適用)で $A = \{\varphi = 1\}$ 、 $P_0(A) = \alpha$ 、 $P_1(A) = 1 - \beta$ 。第2式: 定理 10.11(Bretagnolle–Huber)で $A = \{\varphi = 1\}$ 、 $P_0(A) + P_1(A^c) = \alpha + \beta$ 。□

系 11.3(両方の過誤を δ 以下にするコスト) 【厳密】

$\delta \in (0, 1/2)$ とする。 $\alpha(\varphi) \leq \delta$ かつ $\beta(\varphi) \leq \delta$ なる検定が存在するなら

$$\text{KL}(P_0, P_1) \geq \text{kl}(\delta, 1 - \delta) \geq \log \frac{1}{2.4\delta}.$$

証明. $\text{kl}(x, y)$ は $x \log \frac{x}{y}$ 。 $\forall \delta < 1/2$ より $\forall \alpha \leq \delta, \forall \beta \leq 1 - \delta$ なので、この領域に留まったまま $\text{kl}(\alpha, 1 - \beta) \geq \text{kl}(\delta, 1 - \delta) \geq \text{kl}(\delta, 1 - \delta)$. 定理 11.2 と 命題 10.12. $\square$

$\delta < 1/2$ が要ります。 $\delta \geq 1/2$ だと $\alpha < 1 - \beta$ が保証されず、上の単調性の議論が使えません(そもそも $\text{kl}(\delta, 1 - \delta) \leq 0$ になって主張が無内容)。第 13 講 定理 13.6 でも同じ条件が付きます。

これが BAI の下界の骨格です。「 δ -正当なアルゴリズム = 真の環境 ν と紛らわしい環境 ν' を過誤 δ で区別する検定」と読めば、系 11.3 より $\text{KL}(\mathbb{P}_\nu, \mathbb{P}_{\nu'}) \geq \log \frac{1}{2.4\delta}$ が必要。あとは発散分解でこの KL を $\sum_a \mathbb{E}[N_a(\tau)] \text{KL}(\nu_a, \nu'_a)$ に書き換えれば、 $\mathbb{E}[\tau]$ の下界が出ます。第 13 講は、この 2 行を厳密にするだけです。

定理 11.4(Neyman–Pearson の補題) 【証明省略】

P_0, P_1 が共通支配測度 λ に関して密度 p_0, p_1 を持つとする。 $\varphi^* := \mathbf{1}\{p_1 > c p_0\}$ (必要なら境界でランダム化) は、 $\alpha(\varphi^*) = \alpha$ を満たす検定の中で β を最小にする。

出典: L&S Exercise 14.14–14.15 / Lehmann–Romano, *Testing Statistical Hypotheses*, Theorem 3.2.1。要点は「最強検定は尤度比検定である」。BAI の停止統計量が尤度比の形をしているのは偶然ではありません。

11.2 逐次確率比検定 (SPRT)

定義 11.5(Wald の SPRT) 【厳密】

i.i.d. 観測 $X_1, X_2, \dots$ に対し尤度比

$$\Lambda_n := \prod_{i=1}^n \frac{p_1(X_i)}{p_0(X_i)}$$

を計算し、境界 A_0

命題 11.6(Wald の不等式) 【厳密】

$\alpha := P_0(\Lambda_\tau \geq A)$ とすると $\alpha \leq 1/A$ 。

証明. (Λ_n) は P_0 の下で非負マルチンゲールで $\mathbb{E}_0[\Lambda_0] = 1$ (命題 5.5)。Ville の不等式 (定理 7.3) より

$$P_0 \left(\sup_n \Lambda_n \geq A \right) \leq \frac{1}{A}. \quad \square$$

$A = 1/\delta$ と取れば第一種の過誤は δ 以下。これが「 δ の予算で全時刻を買う」の最も単純な形です。BAI の Chernoff 停止則は、この構造の多仮説版です。

定理 11.7 (Wald–Wolfowitz の最適性) 【証明省略】

同じ過誤確率 (α, β) を持つすべての(逐次)検定の中で、SPRT は $\mathbb{E}_0[\tau]$ と $\mathbb{E}_1[\tau]$ をともに最小にする。

出典: Wald & Wolfowitz (1948)。単純仮説対単純仮説でのみ成立する強い結果です。BAI は複合仮説(「腕 1 が最適」は μ の集合)なので、そのままは使えません。この「単純 → 複合」のギャップが、BAI で GLR が必要になる理由です。

11.2.1 Wald の近似 【直感】

境界での「オーバーシュート」を無視すると

$$A \approx \frac{1-\beta}{\alpha}, \quad B \approx \frac{\beta}{1-\alpha}, \quad \mathbb{E}_0[\tau] \approx \frac{(1-\alpha) \log B + \alpha \log A}{-\text{KL}(P_0, P_1)}.$$

これは厳密ではありません(オーバーシュートは実際には無視できない量です)。しかし $\delta \rightarrow 0$ の漸近では

$$\mathbb{E}_0[\tau] \sim \frac{\log(1/\delta)}{\text{KL}(P_0, P_1)}$$

が正しく、これが BAI のサンプル複雑度 $T^*(\nu) \log(1/\delta)$ の 2 腕版に対応します。 $T^*(\nu)$ は「最悪の対立仮説に対する $1/\text{KL}$ 」の一般化だと思ってよい。

11.3 一般化尤度比(GLR)

定義 11.8 【厳密】

パラメータ空間 Θ が $\Theta_0 \sqcup \Theta_1$ に分かれているとき、観測 x に対する一般化尤度比統計量を

$$\text{GLR}(x) := \log \frac{\sup_{\theta \in \Theta_1} L(\theta; x)}{\sup_{\theta \in \Theta_0} L(\theta; x)}$$

と定める(L は尤度)。

11.3.1 バンディットでの GLR

第3講の canonical model で、腕の平均を $\mu = (\mu_1, \dots, \mu_K)$ 、指数型分布族 (§ 10.1.1) とする。時刻 t での対数尤度は、方策の項を除くと

$$\ell_t(\mu') = \sum_{a=1}^K \sum_{s: A_s=a} \log p_{\mu'_a}(X_s).$$

命題 11.9(指数型分布族での GLR の閉形式) 【厳密】

$d(x, y) := \text{KL}(\nu_x, \nu_y)$ (平均パラメータ表示) とする。 $\hat{\mu}_a(t)$ を腕 a の経験平均、 $N_a(t)$ をその回数とする。 $\hat{\mu}_a(t) > \hat{\mu}_b(t)$ のとき、仮説「 $\mu_a \leq \mu_b$ 」に対する GLR は

$$Z_{a,b}(t) := \log \frac{\sup_{\mu': \mu'_a \geq \mu'_b} L(\mu')}{\sup_{\mu': \mu'_a \leq \mu'_b} L(\mu')} = N_a(t) d(\hat{\mu}_a(t), \hat{\mu}_{a,b}(t)) + N_b(t) d(\hat{\mu}_b(t), \hat{\mu}_{a,b}(t)),$$

ここで

$$\hat{\mu}_{a,b}(t) := \frac{N_a(t)\hat{\mu}_a(t) + N_b(t)\hat{\mu}_b(t)}{N_a(t) + N_b(t)} \quad (\text{重み付き算術平均}).$$

証明. 指数型分布族 $p_\theta(x) = \exp(\theta x - b(\theta))$ 、 $\mu(\theta) = b'(\theta)$ とする。腕 a に関する対数尤度は $\theta_a S_a - N_a b(\theta_a)$ ($S_a = N_a \hat{\mu}_a$) で、これは $\mu'_a = \hat{\mu}_a$ で最大。よって分子は制約なしの最大値。

分母: $\mu'_a \leq \mu'_b$ の制約下では、 $\hat{\mu}_a > \hat{\mu}_b$ のとき最適解は $\mu'_a = \mu'_b =: m$ (境界) で、他の腕は $\hat{\mu}$ のまま。この m を求める。

対数尤度の減少量を KL で書く。標準的な等式

$$[\theta(\hat{\mu}_a) S_a - N_a b(\theta(\hat{\mu}_a))] - [\theta(m) S_a - N_a b(\theta(m))] = N_a d(\hat{\mu}_a, m)$$

(実際、左辺 = $N_a[(\theta(\hat{\mu}_a) - \theta(m))\hat{\mu}_a - b(\theta(\hat{\mu}_a)) + b(\theta(m))]$ = $N_a d(\hat{\mu}_a, m)$ 、§ 10.1.1 の定義そのもの) が成り立つので、

$$Z_{a,b}(t) = \min_m [N_a d(\hat{\mu}_a, m) + N_b d(\hat{\mu}_b, m)].$$

m について微分する。 $\frac{\partial}{\partial m} d(x, m) = \theta'(m)(m - x)$ なので (§ 10.1.1 の定義を m で微分し $\mu(\theta(m)) = m$ を使う)

$$\frac{\partial}{\partial m} [N_a d(\hat{\mu}_a, m) + N_b d(\hat{\mu}_b, m)] = \theta'(m) [N_a(m - \hat{\mu}_a) + N_b(m - \hat{\mu}_b)].$$

$\theta'(m) = 1/b''(\theta(m)) > 0$ なので、零点は $m = \hat{\mu}_{a,b}$ ただ一つ。二階微分の符号から最小点。□

注目すべき点: 分布族が何であれ(ベルヌーイ・ガウス・ポアソン・指数)、最適な m は重み付き算術平均になります。 d の形は族ごとに違うのに、最小点は同じ。これは指数型分布族の平均パラメータ化の性質です。

系 11.10(ガウスの場合) 【厳密, 検証:数値】

単位分散ガウスでは $d(x, y) = (x - y)^2/2$ なので

$$Z_{a,b}(t) = \frac{N_a(t)N_b(t)}{2(N_a(t) + N_b(t))} (\hat{\mu}_a(t) - \hat{\mu}_b(t))^2.$$

証明. $m = \hat{\mu}_{a,b}$ を代入して整理する。 $\hat{\mu}_a - m = \frac{N_b(\hat{\mu}_a - \hat{\mu}_b)}{N_a + N_b}$ 、 $\hat{\mu}_b - m = \frac{N_a(\hat{\mu}_b - \hat{\mu}_a)}{N_a + N_b}$ より

$$\frac{N_a}{2} \cdot \frac{N_b^2(\hat{\mu}_a - \hat{\mu}_b)^2}{(N_a + N_b)^2} + \frac{N_b}{2} \cdot \frac{N_a^2(\hat{\mu}_a - \hat{\mu}_b)^2}{(N_a + N_b)^2} = \frac{N_a N_b (N_a + N_b)}{2(N_a + N_b)^2} (\hat{\mu}_a - \hat{\mu}_b)^2. \quad \square$$

【検証:数値】 `check_glr_closed_form`: ランダムな $(K, N, \hat{\mu})$ 2000 組で、閉形式と m のグリッド最小化を比較。最大相対誤差 1.0×10^{-7} (グリッド分解能の範囲)。

定義 11.11(Chernoff 統計量) 【厳密】

$\hat{a}_t := \arg \max_a \hat{\mu}_a(t)$ とし

$$Z(t) := \min_{b \neq \hat{a}_t} Z_{\hat{a}_t, b}(t)$$

を Chernoff 統計量という (Chernoff 1959 に由来)。「経験的最良腕が本当に最良である」という主張の、最も弱い証拠を測っている。

min を取ることの意味: 「腕 $\hat{a}_t$ が最適」を示すには、すべての $b \neq \hat{a}_t$ に対して「 $\hat{a}_t$ が b より良い」を示す必要がある。多重検定なので最も反証しにくい b が律速になる。だから min。

これが第14講の $\inf_{\nu' \in \text{Alt}}$ の経験版です。実際、

$$Z(t) = \inf_{\nu' \in \text{Alt}(\hat{\nu}(t))} \sum_{a=1}^K N_a(t) d(\hat{\mu}_a(t), \mu'_a)$$

と書けます(第14講 系 14.4 で示す)。下界の式が、そのまま停止統計量になっている。

11.4 e-value と任意時刻有効推測

定義 11.12 【厳密】

H_0 の下での確率測度を P_0 とする。

- e-value: 非負確率変数 E で $\mathbb{E}_0[E] \leq 1$ なるもの。
- test マルチンゲール: P_0 の下での非負マルチンゲール (E_t) で $E_0 = 1$ 。
- e-process: 非負適合過程 (E_t) で、任意の停止時刻 τ について $\mathbb{E}_0[E_\tau] \leq 1$ なるもの。

$\tau = \infty$ の規約: e-process の定義で τ は ∞ を取りうるので、 E_∞ を決めておく必要があります。標準的には $E_\infty := \limsup_{t \rightarrow \infty} E_t$ と定めます(非負優マルチンゲールなら極限が a.s. 存在するので $\lim$ と同じ)。この規約のもとで、下の命題 11.13.3 は $\{\tau = \infty\}$ 上でも意味を持ちます。 $\{\tau < \infty\}$ 上でしか主張しない流儀もありますが、Ville の不等式(系 7.4)は $\sup$ で言っているので、強い方の規約を取っておく方が使いやすい。

命題 11.13 【厳密】

1. e-value E について $P_0(E \geq 1/\delta) \leq \delta$ 。
2. test マルチンゲール(より一般に $E_0 \leq 1$ なる非負優マルチンゲール)について $P_0(\exists t : E_t \geq 1/\delta) \leq \delta$ 。
3. 非負優マルチンゲールは e-process である。

証明. 1: マルコフの不等式(命題 9.1)。2: Ville の不等式(系 7.4)。

3: 有界停止時刻については系 5.11 から $\mathbb{E}_0[E_{t \wedge \tau}] \leq \mathbb{E}_0[E_0] \leq 1$ 。一般の τ については、非負性より $E_{t \wedge \tau} \rightarrow E_\tau$ a.s. ($\{\tau < \infty\}$ 上では有限時刻で一致し、 $\{\tau = \infty\}$ 上では $E_{t \wedge \tau} = E_t \rightarrow E_\infty$ — 非負優マルチンゲールの収束定理、定理 7.7)。Fatou の補題より

$$\mathbb{E}_0[E_\tau] = \mathbb{E}_0\left[\lim_t E_{t \wedge \tau}\right] \leq \liminf_t \mathbb{E}_0[E_{t \wedge \tau}] \leq 1. \quad \square$$

3 の証明に Fatou を使っているところが要点です。非負性のおかげで、任意停止定理の面倒な仮定なしに $\leq$ の向きだけは常に言える。e-process は「 $\leq$ しか要らない」という発想の産物で、だからこそ複合仮説や非 i.i.d. に広く適用できます。

11.4.1 p-value との違い 【直感】

	p-value	e-value
定義	$P_0(p \leq u) \leq u$	$\mathbb{E}_0[E] \leq 1$
合成	独立でも単純に掛けられない	積が e-value(独立なら)
逐次的	「覗き見」で壊れる	test マルチンゲールなら壊れない
直感	「 H_0 の下でこれ以上極端な値が出る確率」	「 H_0 に対して賭けたときの資産倍率」

賭けの解釈: E_t を「初期資金 1 で H_0 に逆張りしたときの資産」と読む。 H_0 が真なら公平な賭けなので資産は増えない($\mathbb{E}_0[E_t] \leq 1$)。資産が $1/\delta$ 倍になったら「 H_0 は怪しい」と結論してよく、その誤判定確率が δ 以下であることが Ville の不等式。Track-and-Stop の停止規則は、まさにこれをやっています。

11.4.2 BAI との接続

Chernoff 停止則

$$\tau_\delta = \min\{t : Z(t) > \beta(t, \delta)\}$$

は、「すべての $b \neq \hat{a}_t$ について、仮説『腕 b の方が良い』を水準 δ で棄却できた最初の時刻」と読めます。

- $\exp(Z_{a,b}(t))$ は $H_0 : \mu_a \leq \mu_b$ の下での GLR 型の e-process の候補ですが、複合仮説なので $\mathbb{E}_0[\exp(Z_{a,b}(t))] \leq 1$ はそのままでは成り立ちません。だから $\beta(t, \delta) = \log(1/\delta)$ ではなく、 $\log t$ や $\log \log t$ の余分が入る。
- 余分の正体は「複合仮説の中での上限を取ったコスト」+「全時刻を取ったコスト」です。第8講 § 8.4 の表がこの分解に対応します。

これが BAI の閾値設計問題の全体像です。「GLR は e-process でないので、e-process にするための補正が要る」。Kaufmann–Koolen (2021) の仕事は、この補正を最小にすることでした。 【要出典確認】

11.5 BAI は逐次多重検定である 【直感 + 位置づけ】

まとめると、固定信頼度 BAI は次の構造を持ちます。

検定の言葉	BAI の言葉
帰無仮説の族 $\{H_b : \mu_b \geq \mu_{a^*}\}_{b \neq a^*}$	対立バンディット環境 $\text{Alt}(\nu)$
すべての H_b を同時に棄却	最適腕を同定
family-wise error rate $\leq \delta$	δ -正当性
逐次的にデータを取る	サンプリング則 π
どの仮説にサンプルを割くか選べる	これが多重検定にない BAI 固有の自由度
期待サンプルサイズの最小化	サンプル複雑度 $\mathbb{E}[\tau]$

最後の行が決定的です。古典的な多重検定では観測は与えられたものですが、BAI ではどの仮説の証拠を集めるかを選べる。この自由度の最適な使い方が $w^*(\nu)$ であり、第14講の主題です。

田畑研の "bad arm existence checking problem" (Machine Learning 誌, 2020) は、まさにこの「逐次多重検定」の枠組みを明示的に採用した定式化です。第18・19講で扱います。【要出典確認】(巻・号・ページは未照合)

11.6 まとめ

- 過誤確率と KL: $\text{kl}(\alpha, 1 - \beta) \leq \text{KL}(P_0, P_1)$ (DPI の系)。両方 δ 以下にするには $\text{KL} \geq \text{kl}(\delta, 1 - \delta) \approx \log(1/\delta)$ が必要。
- SPRT の第一種過誤の評価は Ville の不等式そのもの。単純仮説では最適 (Wald–Wolfowitz)。
- GLR の閉形式: 指数型分布族なら $Z_{a,b} = N_a d(\hat{\mu}_a, m) + N_b d(\hat{\mu}_b, m)$ 、 m は重み付き算術平均。ガウスなら $\frac{N_a N_b}{2(N_a + N_b)} (\hat{\mu}_a - \hat{\mu}_b)^2$ 。
- Chernoff 統計量 $Z(t) = \min_{b \neq \hat{a}_t} Z_{\hat{a}_t, b}(t)$ は、下界の $\inf_{\nu' \in \text{Alt}}$ の経験版。
- e-value / e-process: $\mathbb{E}_0[E_\tau] \leq 1$ 。非負優マルチンゲールは e-process (証明は Fatou)。
- BAI = 「どの仮説にサンプルを割くか選べる逐次多重検定」。

演習(詳細は B-exercises.md § 11)

- ★11-1 定理 11.2 の 2 つの不等式を、それぞれ系 10.7 と 定理 10.11 から導け。
- ★11-2 命題 11.9 を、ベルヌーイの場合に具体的に確認せよ ($d = \text{kl}$ 、 $m =$ 重み付き平均)。
- ★11-3 系 11.10 の計算を最後まで実行せよ。
- ★11-4 命題 11.6 を Ville の不等式から導き、 $A = 1/\delta$ のときの第一種過誤を評価せよ。
- ☆11-5 命題 11.13.3 の証明で Fatou の補題を使う箇所を明示し、なぜ任意停止定理の (a)(b)(c) が要らないかを説明せよ。
- ☆11-6 $\exp(Z_{a,b}(t))$ が $H_0 : \mu_a \leq \mu_b$ の下で e-process にならない理由を、 $K = 2$ 、ガウスの場合に具体的に示せ (ヒント: $\sup$ を取る前の尤度比は e-process)。

← 前の講 | 次の講: バンディットの定式化 →